

Sumarização de dados

Média, mediana, moda, variância, desvio padrão, distribuição de frequência

André Gustavo dos Santos

Departamento de Informática
Universidade Federal de Viçosa

INF222 - 2022/2

– Fonte do material

O conteúdo a seguir foi preparado e gentilmente cedido para uso nesta disciplina pela prof^a Elizabeth Wanner, do PPGMMC, CEFET-MG.

Estatística: ciência dos dados
oooooooo

Medidas de Centro
ooooooo

Medidas de Variação
ooooooooo

Distribuição de frequência
ooooooo

Tópicos da aula

1 Estatística: ciência dos dados

2 Medidas de Centro

3 Medidas de Variação

4 Distribuição de frequência

Estatística

- A estatística surgiu por demanda do Estado para coletar dados com fins tributários
- Contudo, foi a partir do século XX que a Estatística desenvolveu-se como uma área específica do conhecimento: Estatística Inferencial
- Resumidamente: estatística é a ciência dos dados
- Trata-se de uma ciência MEIO, que objetiva instrumentalizar a coleta, classificação, sumarização, organização, análise e interpretação de dados

Probabilidade X Estatística

Probabilidade

Dada a piscina de bolas, qual é a probabilidade de se obter uma certa combinação de cores?



Estatística

Dadas as cores de poucas bolas, o que eu conheço sobre a piscina de bolas?



Inferência Estatística: usando amostras para obter conclusões sobre populações

População, Amostra e Observação

População: a totalidade (universo) de itens, objetos ou pessoas que possuem uma determinada característica em comum

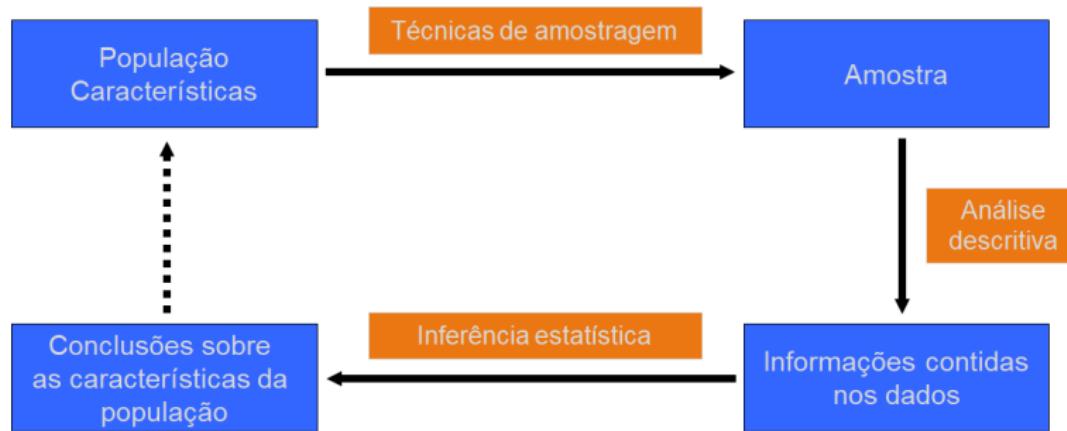


Amostra: uma parte representativa da população

Observação: é um único elemento de uma amostra, um ponto individualmente coletado



Estatística



Motivação

Case 1: Idade das Melhores Atrizes e dos Melhores Atores listadas em ordem desde a primeira cerimônia de premiação do Oscar em 1928.

PERGUNTAS:

- Os prêmios na Academia envolvem discriminação com base na idade?
- Há diferenças sérias e importantes entre as idades das Melhores Atrizes e as idades dos Melhores Atores?
- Existe uma tendência das Melhores Atrizes serem mais jovens que os Melhores Atores?

Idade das Melhores Atrizes e dos Melhores Atores

Melhores atrizes

22	37	28	63	32	26
31	27	27	28	30	26
29	24	38	25	29	41
30	35	35	33	29	38
54	24	25	46	41	28
40	39	29	27	31	38
29	25	35	60	43	35
34	34	17	37	42	41
36	32	41	33	31	74
33	50	38	61	21	41
26	80	42	19	33	35
45	49	39	34	26	25
33	35	35	28		

Melhores atores

44	41	62	52	41	34
34	52	41	37	38	34
32	40	43	56	41	39
49	57	41	38	42	52
51	35	30	39	41	44
49	35	47	31	47	37
57	42	45	42	44	62
43	42	48	49	56	38
60	30	40	42	36	76
39	53	45	36	62	43
51	32	42	54	52	37
38	32	45	60	46	40
36	47	29	43		

Entendendo os dados

OBJETIVOS:

- Melhor compreensão dos dados com o propósito da apresentação
- Organizar e resumir um conjunto de dados em tabelas
- Organizar e resumir um conjunto de dados em gráficos

Características dos dados

Algumas definições:

- **Dados brutos:** dados como foram oferecidos ou recolhidos
- **Centro:** valor representativo ou médio do conjunto
- **Variação:** quanto os valores dos dados variam entre eles
- **Distribuição:** natureza ou forma da distribuição dos dados
- **Outliers:** valores que se localizam muito longe da grande maioria dos outros valores amostrais
- **Tempo:** características dos dados que mudam com o tempo

Medidas de Centro

Definição: um número que representa o valor central de um conjunto de dados

- média
- mediana
- moda
- ponto médio

Média Aritmética

- É a medida de centro encontrada pela adição dos valores e divisão do total pelo número de valores

$$\bar{x} = \frac{\sum_i x_i}{n} = \frac{x_1 + \dots + x_n}{n}$$

em que $\{x_1, x_2, x_3, \dots, x_n\}$ é uma amostra de dados de tamanho n

- Vantagem: fácil de entender e de calcular
- Desvantagem: sensível a qualquer valor; um valor excepcional pode afetar drasticamente a média
- Notação para a média populacional: μ

Mediana

- É a medida de centro que é o valor do meio quando os dados originais estão arranjados em ordem crescente de magnitude
- Cerca de metade dos valores no conjunto de dados está abaixo da mediana e metade está acima dela

- Procedimento:
 - 1 Ordene os valores
 - 2 Se o número de valores for ímpar, a mediana será o número localizado no meio exato da lista ordenada
 - 3 Se o número de valores for par, a mediana será encontrada pelo cálculo da média aritmética dos dois números do meio
- Vantagem: insensível a valores extremos

Exemplo

Considere o conjunto de dados amostrais:

$$\{5.40, 1.10, 0.42, 0.73, 0.48, 1.10\}$$

Média:

$$\bar{x} = \frac{5.40 + 1.10 + 0.42 + 0.73 + 0.48 + 1.10}{6} = 1.538$$

Mediana:

- 1 Ordene os valores: 0.42, 0.48, 0.73, 1.10, 1.10, 5.40
- 2 Como temos 6 valores (número par), a mediana é encontrada pelo cálculo da média dos dois valores do meio (o 3º e o 4º):

$$\tilde{x} = \frac{0.73 + 1.10}{2} = 0.915$$

Obs: Valores bem diferentes para a média e mediana: efeito do 5.40.

Moda

Definição: É o valor que ocorre mais frequentemente

- Quando dois valores ocorrem com a mesma maior frequência, cada um é uma moda e o conjunto é dito bimodal
- Quando mais de dois valores de dados ocorrem com a mesma maior frequência, cada um é uma moda e o conjunto é dito multimodal
- Quando nenhum valor se repete, dizemos que não há moda

Exemplo:

- 1 {5.40, 1.10, 0.42, 0.73, 0.48, 1.10}: O número 1.10 é a moda pois aparece duas vezes (maior frequência)
- 2 {27, 27, 27, 55, 55, 55, 88, 88}: Os números 27 e 55 são, ambos, modas e, portanto, o conjunto é dito bimodal

Ponto Médio

Definição: É a medida de centro que é exatamente o valor a meio caminho entre o maior valor e o menor valor no conjunto de dados

$$\text{Ponto Médio} = \frac{\text{valor máximo} + \text{valor mínimo}}{2}$$

- Raramente usado porém fácil de calcular
- Sensível a casos extremos

Exemplo:

$$\{5.40, 1.10, 0.42, 0.73, 0.48, 1.10\}$$

$$\text{Ponto Médio} = \frac{5.40 + 0.42}{2} = 2.91$$

Idade das Melhores Atrizes e dos Melhores Atores

	Melhores Atrizes	Melhores Atores ¹
Média	35.4	?
Mediana	33.5	?
Moda	35	?
Ponto Médio	48.5	?

¹ Exercício para a próxima aula

Medidas de Variação

Considere três conjuntos de dados:

$$A = \{6, 6, 6\}$$

$$B = \{4, 7, 7\}$$

$$C = \{1, 3, 14\}$$

Observe que a média é a mesma: $\bar{A} = \bar{B} = \bar{C} = 6.0$.

No entanto, as amostras são muito diferentes nas quantidades que os dados variam.

Objetivo: Medir tais variações de maneira sistemática.

Medidas de Variação

- Amplitude
- Variância
- Desvio Padrão
- Coeficiente de Variação

Amplitude

Definição: é a diferença entre o maior valor e o menor valor

$$A = \{6, 6, 6\} \rightarrow \text{Amplitude}_A = 6 - 6 = 0$$

$$B = \{4, 7, 7\} \rightarrow \text{Amplitude}_B = 7 - 4 = 3$$

$$C = \{1, 3, 14\} \rightarrow \text{Amplitude}_C = 14 - 1 = 13$$

Variância

Definição: é a média da variação quadrática dos valores em torno da média. Um desvio médio quadrático dos valores em relação à média.

Variância populacional:

$$\sigma^2 = \frac{\sum(x_i - \bar{x})^2}{n}$$

Variância amostral:

$$s^2 = \frac{\sum(x_i - \bar{x})^2}{n - 1}$$

Variância

Propriedades:

- valor sempre não negativo;
- valores maiores indicam maior variação dos dados;
- pode crescer muito com a inclusão de um ou mais dados que estão muito afastados dos demais;
- a variância de uma amostra é levemente menor que a variância da população: se os dados tiverem sido tirados de uma amostra, é menos provável que inclua dados extremos, portanto estão mais agrupados que os dados da população;
- na variância amostral, o valor $n - 1$ representa o número de graus de liberdade, considerando os desvios $x_i - \bar{x}$;
- isto é importante quando a amostra for pequena; para n grande, existe pouca diferença entre as fórmulas.

Desvio Padrão

Definição: é raiz quadrada da média da variação quadrática dos valores em torno da média:

$$\sigma = \sqrt{\frac{\sum(x_i - \bar{x})^2}{n}} \text{ ou } s = \sqrt{\frac{\sum(x_i - \bar{x})^2}{n-1}}$$

Propriedades:

- mesmas propriedades da variância;
- porém, com a mesma unidade dos dados originais.

Desvio Padrão

Considerando toda a população:

$$A = \{6, 6, 6\} \rightarrow \sigma_A = \sqrt{\frac{(6-6)^2 + (6-6)^2 + (6-6)^2}{3}} = 0$$

$$B = \{4, 4, 7\} \rightarrow \sigma_B = \sqrt{\frac{(4-6)^2 + (7-6)^2 + (7-6)^2}{3}} = 1.15$$

$$C = \{1, 3, 14\} \rightarrow \sigma_C = \sqrt{\frac{(1-6)^2 + (3-6)^2 + (14-6)^2}{3}} = 5.71$$

Coeficiente de Variação

Definição: O coeficiente de variação para um conjunto de dados amostrais não negativos, expresso como um percentual, descreve o desvio padrão relativo à média.

$$CV = \frac{s}{\bar{x}} \times 100\%$$

Compara a variação para valores originados de diferentes populações.

Idade das Melhores Atrizes e dos Melhores Atores

	Melhores Atrizes	Melhores Atores
Média	35.4	?
Mediana	33.5	?
Moda	35	?
Ponto Médio	48.5	?
Amplitude	63	?
Desvio Padrão	11.36	?
Variância	129.10	?
Coef. de Variação	32.08 %	?

Dados em tabelas

- Uma tabela ou série estatística é o conjunto de dados agrupados segundo algum critério específico.
- A forma mais simples é aquela em que se organiza os dados por **categorias ou classes**, de acordo com o que se quer estudar.
- Esta tabela se chama **distribuição de frequência** dos dados: listar os valores dos dados individualmente ou por grupos de intervalo, juntamente com suas frequências correspondentes: absoluta (em valores inteiros) e relativa (em valores percentuais), bem como na versão acumulada de cada uma.

Classificação dos dados

- As classes ou categorias devem ser abrangentes, escolhidas de forma que toda resposta possa ser incluída.
Sugestão: classe “outros” ou “100 ou mais”.
- As categorias devem ser distintas e não ser ambíguas.
Sugestão: “de 0 até 20” e “maior que 20 até 40”.
- As categorias não devem ser muito numerosas, para não ficar muito difícil de se analisar.
Sugestão: algo entre 5 ou 10 classes.

Construção da tabela

- Seja claro sobre o que você deseja que a tabela mostre.
- Liste primeiro a variável de interesse.
- Uma tabela pode resumir mais de uma variável ao mesmo tempo.
- Duas ou três tabelas simples são melhores que uma grande e complicada.
- Toda linha e coluna deve receber um título claro.
- Se possível, inclua os totais de cada linha e coluna.
- A fonte de informação deve ser informada abaixo da tabela.
- Inclua qualquer outra informação útil em notas de rodapé.

Distribuição de Frequência

Estudo das Idades das Melhores Atrizes

Idade das atrizes	Frequência absoluta
≤ 30	28
31-40	30
41-50	12
51-60	2
61-70	2
≥ 71	2

Conceitos:

- limites inferiores e superiores das classes
- amplitude das classes
- pontos médios das classes
- fronteiras de classes

Construindo a distribuição de frequência

Passo 1: Escolher o número de classe desejado: $n = 6$

Passo 2: Calcular a amplitude de classe:

$$A = \frac{\max - \min}{n} = \frac{80 - 21}{6} = 9.833 \approx 10$$

Passo 3: Definir os limites superiores e inferiores:

1^a Classe 21 - 30 ; 2^a Classe 31 - 40; 3^a Classe 41 - 50 ; 4^a Classe 51 - 60; 5^a Classe 61-70; 6^a Classe 71 - 80

Passo 4: Calcular frequência absoluta F : fazer a contagem de elementos em cada classe.

Passo 5: Calcular frequência relativa Fr e acumulada Fac , além da relativa acumulada $Frac$.

Frequênci a relativa e acumulada

Idade das atrizes	F	Fr	Fac	Frac
≤ 30	28	37 %	28	37 %
31 - 40	30	39 %	58	76 %
41-50	12	15 %	70	91 %
51-60	2	3 %	72	94 %
61-70	2	3 %	74	97 %
≥ 71	2	3 %	76	100 %
TOTAL (Σ)	76	100 %	—	—

Atividade 1 *(consulte enunciado completo e forma de entrega no PVANet Moodle)*

- Calcular as medidas de centro e de variação para os dados dos atores.
- Construir a distribuição de frequência para os dados dos atores.
- Procurar responder às perguntas colocadas:
 - Os prêmios na Academia envolvem discriminação com base na idade?
 - Há diferenças sérias e importantes entre as idades das Melhores Atrizes e as idades dos Melhores Atores?
 - Existe uma tendência das Melhores Atrizes serem mais jovens que os Melhores Atores?